

Universidad de Valladolid

ESCUELA DE INGENIERÍA INFORMÁTICA

Trabajo de Fin de Grado

Grado en Ingeniería Informática  
(Mención de Computación)

**Implementación de algoritmos de  
aprendizaje automático para la  
predicción del consumo eléctrico en el  
sector energético**

Autor:  
D.Pablo Bueno Sánchez

# Índice

Agradecimientos	4
Resumen	5
Abstract	6
Índice de Figuras	6
Índice de Tablas	7
Índice de Ecuaciones	8
1. Introducción	8
1.1. Contexto y Motivación . . . . .	8
1.2. Objetivos . . . . .	8
1.3. Organización y Estructura de la Memória . . . . .	8
2. Estado del Arte	8
2.1. Introducción . . . . .	8
2.2. Inteligencia Artificial . . . . .	8
2.3. Machine Learning . . . . .	8
2.3.1. aprendizaje Supervisado . . . . .	8
2.3.2. Regresión Lineal . . . . .	9
2.3.3. Árboles de Decisión . . . . .	9
2.3.4. XGBoost . . . . .	9
2.3.5. Otros Modelos . . . . .	9
2.4. Deep Learning . . . . .	9

2.4.1.	Redes Neuronales Artificiales . . . . .	9
2.4.2.	Redes Neuronales Recurrentes (RNN) . . . . .	9
2.4.3.	Backpropagation Through Time y problemas de evanescencia / explosión del gradiente . . . . .	10
2.4.4.	Redes Long Short-Term Memory (LSTM) . . . . .	11
2.4.5.	Gated Recurrent Unit (GRU) . . . . .	11
2.4.6.	Redes Neuronales Convolucionales (CNN) . . . . .	11
2.4.7.	Autoregressive Integrated Moving Average (ARIMA) . . . . .	11
2.5.	Series Temporales . . . . .	11
2.5.1.	Tendencia . . . . .	12
2.5.2.	Estacionalidad . . . . .	12
2.5.3.	Residual . . . . .	12
2.5.4.	Series Estacionarias . . . . .	12
2.5.5.	Predicción . . . . .	12
<b>3.</b>	<b>Datos</b>	<b>12</b>
3.1.	Obtención . . . . .	12
3.2.	Descripción . . . . .	13
<b>4.</b>	<b>Predicción del consumo energético</b>	<b>16</b>
4.1.	Base teórica . . . . .	16
4.1.1.	Algoritmos . . . . .	16
4.1.2.	Funciones de pérdida . . . . .	16
4.1.3.	Optimizadores . . . . .	16
4.1.4.	Modelo 1 . . . . .	16
4.1.5.	Modelo 2 . . . . .	16

4.1.6. Modelo 3 . . . . .	16
<b>5. Predicción de producción energética</b>	<b>16</b>
5.1. Base teórica . . . . .	16
5.1.1. Algoritmos . . . . .	16
5.1.2. Funciones de pérdida . . . . .	16
5.1.3. Optimizadores . . . . .	16
5.2. Implementación . . . . .	16
5.2.1. Preprocesamiento de Datos . . . . .	16
5.2.2. Clasificación Modelo 1 . . . . .	16
5.2.3. Clasificación Modelo 2 . . . . .	16
5.2.4. Clasificación Modelo 3 . . . . .	16
<b>6. Conclusiones</b>	<b>17</b>
6.1. Predicción de consumo energético . . . . .	17
6.2. Predicción de producción energética . . . . .	17
6.3. Comparación de resultados . . . . .	17
6.4. Aplicabilidad de los algoritmos de predicción . . . . .	17
<b>7. Trabajo futuro</b>	<b>17</b>
<b>Bibliografía</b>	<b>17</b>

## Agradecimientos

## Resumen

## Abstract

## Índice de Figuras

## Índice de Tablas



# Índice de Ecuaciones

## 1. Introducción

### 1.1. Contexto y Motivación

### 1.2. Objetivos

### 1.3. Organización y Estructura de la Memória

## 2. Estado del Arte

### 2.1. Introducción

### 2.2. Inteligencia Artificial

### 2.3. Machine Learning

Dentro de la computación, los algoritmos son los encargados de regir el compotamiento de las máquinas para la resolución de problemas. Estos algoritmos reciben una entrada y, a partir de una serie de pasos, producen una salida deseada para un problema en concreto. Sin embargo, existen problemas para los cuales no se tiene ningún algoritmo, aquí es donde es posible hacer uso del machine learning.

El Machine Learning es una rama dentro de la Inteligencia Artificial la cual se encarga de permitir a las máquinas extraer, a partir de una gran cantidad de datos, una aproximación fiable de algoritmos para la resolución de diversos problemas.

#### 2.3.1. aprendizaje Supervisado

El aprendizaje supervisado es una categoría del machine learning caracterizada por el uso de datos etiquetados para el entrenamiento de los modelos.

El uso de conjuntos de datos etiquetados permite a los modelos modificar gradualmente su comportamiento para poder ajustarse al modelo final.

Con el fin de poder modificar los componentes del modelo se utilizan funciones de pérdida,

las cuales permiten calcular la precisión de la salida del modelo con respecto a la salida deseada, permitiendo así minimizar el error hasta un mínimo deseable.

### 2.3.2. Regresión Lineal

### 2.3.3. Árboles de Decisión

### 2.3.4. XGBoost

### 2.3.5. Otros Modelos

## 2.4. Deep Learning

### 2.4.1. Redes Neuronales Artificiales

### 2.4.2. Redes Neuronales Recurrentes (RNN)

Las redes neuronales recurrentes o RNN son un tipo de redes neuronales artificiales diseñadas principalmente para la detección de patrones en secuencias de datos [1].




Figura 1: Estructura de una red RNN con función de activación ReLU

Al igual que otros tipos de redes neuronales, como los perceptrones multicapa (MLP), la información se transmite desde la capa de entrada  $\mathbf{X}_t$  hasta la capa de salida  $\mathbf{O}_t$  pasando por el bloque de capa oculta  $\mathbf{H}_t$ . Sin embargo, a diferencia de estas, la entrada del bloque de la capa oculta depende tanto de la entrada  $\mathbf{X}_t$  como de la salida del bloque en su iteración anterior  $\mathbf{H}_{t-1}$ . Ver figura 1.

La salida de los bloques  $\mathbf{H}_t$  y  $\mathbf{O}_t$  viene dada por las fórmulas:

$$\mathbf{H}_t = \phi_h(\mathbf{X}_t \mathbf{W}_{xh} + \mathbf{H}_{t-1} \mathbf{W}_{hh} + \mathbf{b}_h) \quad (1)$$

$$\mathbf{O}_t = \phi_o(\mathbf{H}_t \mathbf{W}_{ho} + \mathbf{b}_o) \quad (2)$$

Donde,  $\mathbf{X}_t$  es la salida de la capa de entrada,  $\mathbf{H}_t$  y  $\mathbf{H}_{t-1}$  son las salidas de la capa oculta en los instantes  $t$  y  $t-1$ ,  $\mathbf{W}_{xh}$ ,  $\mathbf{W}_{hh}$ , y  $\mathbf{W}_{ho}$  son las matrices de pesos entre las diferentes capas

de la neurona y  $\mathbf{b}_h$  y  $\mathbf{b}_o$  son los vectores de bias o sesgo para la capa oculta y la de salida respectivamente.

$\phi_h$  y  $\phi_o$  son las funciones de activación de las capas oculta y de salida respectivamente. En el caso de  $\phi_h$  suele ser la función rectificador (ReLU) o tangente hiperbólica (tanh).

### 2.4.3. Backpropagation Through Time y problemas de evanescencia / explosión del gradiente

Para poder comprender el principal problema de las redes neuronales recurrentes es necesario conocer el funcionamiento del algoritmo de retropropagación a través del tiempo o BPTT (Back-Propagation Through Time).

Con el fin de entrenar una RNN, primero se debe establecer una función de pérdida  $\mathcal{L}$ , la cual nos permite conocer la distancia entre el valor de salida de la neurona  $\mathbf{O}_t$  y el valor real  $\mathbf{Y}_t$ .

$$\mathcal{L}(\mathbf{O}, \mathbf{Y}) = \sum_{t=1}^T \ell_t(\mathbf{O}_t, \mathbf{Y}_t) \quad (3)$$

Con el fin de minimizar dicha distancia, se han de calcular las derivadas parciales de  $\mathcal{L}$  con respecto los pesos de la neurona,  $\mathbf{W}_{xh}$ ,  $\mathbf{W}_{hh}$ , y  $\mathbf{W}_{ho}$ . A partir de la ecuación 2 aplicando la regla de la cadena, se puede obtener:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}_{ho}} = \sum_{t=1}^T \frac{\partial \ell_t}{\partial \mathbf{O}_t} \cdot \frac{\partial \mathbf{O}_t}{\partial \phi_o} \cdot \frac{\partial \phi_o}{\partial \mathbf{W}_{ho}} = \sum_{t=1}^T \frac{\partial \ell_t}{\partial \mathbf{O}_t} \cdot \frac{\partial \mathbf{O}_t}{\partial \phi_o} \cdot \mathbf{H}_t \quad (4)$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}_{hh}} = \sum_{t=1}^T \frac{\partial \ell_t}{\partial \mathbf{O}_t} \cdot \frac{\partial \mathbf{O}_t}{\partial \phi_o} \cdot \frac{\partial \phi_o}{\partial \mathbf{H}_t} \cdot \frac{\partial \mathbf{H}_t}{\partial \phi_h} \cdot \frac{\partial \phi_h}{\partial \mathbf{W}_{hh}} = \sum_{t=1}^T \frac{\partial \ell_t}{\partial \mathbf{O}_t} \cdot \frac{\partial \mathbf{O}_t}{\partial \phi_o} \cdot \mathbf{W}_{ho} \cdot \frac{\partial \mathbf{H}_t}{\partial \phi_h} \cdot \frac{\phi_h}{\partial \mathbf{W}_{hh}} \quad (5)$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}_{hh}} = \sum_{t=1}^T \frac{\partial \ell_t}{\partial \mathbf{O}_t} \cdot \frac{\partial \mathbf{O}_t}{\partial \phi_o} \cdot \frac{\partial \phi_o}{\partial \mathbf{H}_t} \cdot \frac{\partial \mathbf{H}_t}{\partial \phi_h} \cdot \frac{\partial \phi_h}{\partial \mathbf{W}_{xh}} = \sum_{t=1}^T \frac{\partial \ell_t}{\partial \mathbf{O}_t} \cdot \frac{\partial \mathbf{O}_t}{\partial \phi_o} \cdot \mathbf{W}_{ho} \cdot \frac{\partial \mathbf{H}_t}{\partial \phi_h} \cdot \frac{\phi_h}{\partial \mathbf{W}_{xh}} \quad (6)$$

Las ecuaciones 5 y 6, al depender  $\mathbf{H}_t$  de sus valores anteriores, pueden reescribirse como:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}_{hh}} = \sum_{t=1}^T \frac{\partial \ell_t}{\partial \mathbf{O}_t} \cdot \frac{\partial \mathbf{O}_t}{\partial \phi_o} \cdot \mathbf{W}_{ho} \sum_{k=1}^t \frac{\partial \mathbf{H}_t}{\partial \mathbf{H}_k} \cdot \frac{\partial \mathbf{H}_k}{\partial \mathbf{W}_{hh}} \quad (7)$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}_{hh}} = \sum_{t=1}^T \frac{\partial \ell_t}{\partial \mathbf{O}_t} \cdot \frac{\partial \mathbf{O}_t}{\partial \phi_o} \cdot \mathbf{W}_{ho} \sum_{k=1}^t \frac{\partial \mathbf{H}_t}{\partial \mathbf{H}_k} \cdot \frac{\partial \mathbf{H}_k}{\partial \mathbf{W}_{xh}} \quad (8)$$

Para entender el problema de la evanescencia y explosión del gradiente en las RNN es necesario fijarse en la expresión  $\frac{\partial \mathbf{H}_t}{\partial \mathbf{H}_k}$  de las ecuaciones 7 y 8.

El problema de la evanescencia del gradiente se produce cuando, en secuencias largas de datos, se establece unos pesos iniciales menores a 1. A medida que se entrena la red RNN. Los gradientes se hacen menores con cada iteración hasta llegar a desaparecer, provocando que la red no pueda seguir entrenandose.

Con el problema de la explosión del gradiente se da una situación parecida a la evanescencia del gradiente, pero al contrario que esta, al establecer los pesos iniciales a un valor superior a 1, los gradientes se irán haciendo mayores con cada iteración hasta que sean tan grandes que sea imposible entrenar la red debido a que el valor de los pesos sufren grandes cambios en cada actualización, impidiendo encontrar un resultado óptimo.

#### 2.4.4. Redes Long Short-Term Memory (LSTM)

Con el fin de solventar los problemas de la evanescencia y explosión del gradiente de las redes recurrentes, en 1997 se ideó una nueva estructura de red recurrente.

La principal diferencia entre una red LSTM y una RNN es la presencia de un nuevo tipo de memoria a largo plazo la cual ayuda a regular la memoria a corto plazo y predecir la salida de dicha red.

La estructura principal se caracteriza por su división en 3 puertas principales.

La primera de las puertas se denomina “puerta del olvido” ( $\mathbf{F}_t$ ). Es la parte de la red que se encarga de decidir que porcentaje de la memoria a largo plazo ( $\mathbf{C}_{t-1}$ ) se debe olvidar o mantener.

$$\mathbf{F}_t = \sigma(\mathbf{X}_t \mathbf{W}_{xf} + \mathbf{H}_{t-1} \mathbf{W}_{hf} + \mathbf{b}_f) \quad (9)$$

$$\mathbf{F}_t = \sigma(\mathbf{X}_t \mathbf{W}_{xi} + \mathbf{H}_{t-1} \mathbf{W}_{hi} + \mathbf{b}_i) \quad (10)$$

$$\mathbf{F}_t = \sigma(\mathbf{X}_t \mathbf{W}_{xo} + \mathbf{H}_{t-1} \mathbf{W}_{ho} + \mathbf{b}_o) \quad (11)$$

#### 2.4.5. Gated Recurrent Unit (GRU)

#### 2.4.6. Redes Neuronales Convolucionales (CNN)

#### 2.4.7. Autoregressive Integrated Moving Average (ARIMA)

### 2.5. Series Temporales

Una serie temporal es una secuencia de datos obtenidos a lo largo de diferentes momentos ordenados cronológicamente. Dichos datos pueden obtenerse y ordenarse de dos formas diferentes:

- **Equidistante en el tiempo:** Los datos se obtienen en intervalos iguales de tiempo, ya sea de forma diaria, mensual, anual u horaria.
- **No equidistante en el tiempo:** Los datos se obtienen en intervalos desiguales de tiempo, como por ejemplo la medición de los kilómetros recorridos por un vehículo cada vez que se realiza una revisión en el taller.

Una de las cualidades intrínsecas de las series temporales es que los datos adyacentes suelen tener una dependencia entre ellos. Dicha dependencia entre observaciones provee de un gran interés práctico. Una de las áreas de aplicación de dicha dependencia es la de predicción de futuros valores dentro de la serie.

#### 2.5.1. Tendencia

#### 2.5.2. Estacionalidad

#### 2.5.3. Residual

#### 2.5.4. Series Estacionarias

#### 2.5.5. Predicción

asdasd

## 3. Datos

En este apartado se tratará de describir tanto la fuente como una descripción detallada de los datos que se han utilizado para la realización de las diferentes pruebas que se han realizado para el trabajo actual.

### 3.1. Obtención

El trabajo se ha realizado sobre un dataset obtenido de una competición de Kaggle llamada “*Enefit - Predict Energy Behavior of Prosumers*” realizada entre el 1 de Noviembre de 2023 y el 31 de Enero de 2024.

## 3.2. Descripción

El conjunto de datos consta de varios archivos csv con diversas variables tanto energéticas como meteorológicas. Dichos archivos fueron obtenidos para predecir tanto la producción como el consumo de energía de diversas personas en Estonia con instalación de paneles solares en sus hogares.

A continuación se encuentra una descripción de cada archivo y todas sus variables:

### 1. **train.csv:**

- **country:** ID del país.
- **is\_business:** Indica si el consumidor es una empresa o un individuo.
- **product\_type:** ID de un mapa de tipo de contrato.
- **target:** cantidad de consumo o producción del segmento relevante durante la hora.
- **is\_consumption:** Indica si el elemento de la columna ‘target’ es de consumo o producción.
- **datetime:** Hora local de Estonia en EET (UTC+2)/ EEST(UTC+3). Define el inicio del periodo de una hora en el cual se da el valor de ‘target’.
- **data\_block\_id:**
- **row\_id:** Identificador único de la fila
- **prediction\_unit\_id:** Identificador único formado por la unión de las columnas ‘country’, ‘is\_business’ y ‘product\_type’.

### 2. **gas\_prices.csv:**

- **origin\_date:** Fecha en la que los precios diarios se hicieron disponibles.
- **forecast\_date:** Fecha en la que los precios previstos deberían ser relevantes
- **[lowest/highest]\_price\_per\_mwh:** El precio mínimo/máximo del gas natural en el mercado diario ese día de negociación.
- **data\_block\_id**

### 3. **client.csv:**

- **product\_type:**
- **country:** ID del código del país.
- **eic\_count:** Número agregado de puntos de consumo (EICs - European Identifier Code).
- **installed\_capacity:** Capacidad, en KWh, de los paneles solares fotovoltaicos instalados.
- **is\_business:**
- **date:**

- **data\_block\_id:**

#### 4. electricity\_prices.csv:

- **origin\_date:**
- **forecast\_date:**
- **euros\_per\_mwh:** Precio de la electricidad en MWh
- **data\_block\_id:**

#### 5. forecast\_weather.csv:

- **[latitude/longitude]:** Coordenadas del pronóstico.
- **origin\_datetime:** Marca de tiempo de la generación del pronóstico.
- **hours\_ahead:** Horas entre la generación del pronóstico y el propio pronóstico del tiempo. Cada pronóstico cubre un total de 48 horas.
- **temperature:** Temperatura del aire, en grados Celsius, a 2 metros sobre el nivel del suelo. Estimado al final del periodo de 1 hora.
- **dewpoint:** La temperatura del punto de rocío, en grados celsius, a 2 metros sobre el nivel del suelo. Estimado al final del periodo de 1 hora.
- **cloudcover\_[low/mid/high/total]:** Porcentaje de cielo cubierto en las siguientes bandas de altitud: 0-2, 2-6, 6+ y total en km. Estimado al final del periodo de 1 hora.
- **10\_metre\_[u/v]\_wind\_component:** Componente de la velocidad del viento en dirección [este/norte] a 10 metros sobre la superficie, en metros por segundo (m/s). Estimado al final del periodo de 1 hora.
- **data\_block\_id**
- **forecast\_datetime:** Marca de tiempo de la predicción del tiempo. Generado de la suma de 'origin\_datetime' y 'hours\_ahead'. Representa el inicio del periodo de 1 hora donde se pronostican los datos del clima.
- **direct\_solar\_radiation:**
- **surface\_solar\_radiation\_downwards:**
- **snowfall:**
- **total\_precipitation:**

#### 6. historical\_weather.csv:

- **datetime:**
- **temperature:**
- **dewpoint:**
- **rain:**
- **snowfall:**

- **surface\_pressure:**
- **cloudcover\_[low/mid/high/total]:**
- **windspeed\_10m:**
- **winddirection\_10m:**
- **shortwave\_radiation:**
- **direct\_solar\_radiation:**
- **diffuse\_radiation:**
- **[latitude/longitude]:**
- **data\_block\_id:**



## 4. Predicción del consumo energético

### 4.1. Base teórica

#### 4.1.1. Algoritmos

#### 4.1.2. Funciones de pérdida

#### 4.1.3. Optimizadores

#### 4.1.4. Modelo 1

#### 4.1.5. Modelo 2

#### 4.1.6. Modelo 3

## 5. Predicción de producción energética

### 5.1. Base teórica

#### 5.1.1. Algoritmos

#### 5.1.2. Funciones de pérdida

#### 5.1.3. Optimizadores

### 5.2. Implementación

#### 5.2.1. Preprocesamiento de Datos

#### 5.2.2. Clasificación Modelo 1

#### 5.2.3. Clasificación Modelo 2

#### 5.2.4. Clasificación Modelo 3

asdasd w fqf

## 6. Conclusiones

asdjsadjajsd

### 6.1. Predicción de consumo energético

akdjaskdjkasj

### 6.2. Predicción de producción energética

### 6.3. Comparación de resultados

### 6.4. Aplicabilidad de los algoritmos de predicción

## 7. Trabajo futuro

## Bibliografía

## Referencias

- [1] Robin M. Schmidt. «Recurrent Neural Networks (RNNs): A gentle Introduction and Overview». Tesis de mtría. Eberhard-Karls-University Tübingen, 2019.